

Pengujian Algoritma *Long Short Term Memory* untuk Prediksi Kualitas Udara dan Suhu Kota Bandung

Ali Khumaidi^{#1}, Ridwan Raafi'udin^{*2}, Indra Permana Solihin^{*3}

[#]*Program Studi Teknik Informatika, Universitas Krisnadwipayana*

Jl. Kampus Unkris, Jatiwaringin, Jakarta, Indonesia

¹*alikhumaidi@unkris.ac.id*

^{*}*Program Studi Teknik Informatika, UPN Veteran Jakarta*

Jl. Rs. Fatmawati, Pondok Labu, Jakarta, Indonesia

²*raafiudin@upnvj.ac.id*

³*indrapermanasolihin@upnvj.ac.id*

Abstract— This study develops the LSTM modeling to predict time series data of air quality in the city of Bandung from the parameters PM10, ISPU, temperature, and humidity. Modeling LSTM with 4 hidden layers, the number of batch sizes that is 32, the optimizer is adam, value of epoch is 1000, and the loss function using Mean Squared Error. The LSTM modeling results show that the network has a fairly good performance in predicting training and testing. The modeling produces a fairly good prediction accuracy for 3 parameters (temperature, humidity, ISPU). This is indicated by the predicted RMSE value which is smaller than the standard deviation value of the dataset test. However, the prediction results generated from the four test parameters based on the order of the best are the prediction of humidity, temperature, ISPU, and PM10 with unfavorable predictive results.

Keywords— LSTM, prediction, air quality, PM10, ISPU

Abstrak— Penelitian ini mengembangkan pemodelan LSTM untuk memprediksi data *time series*, yaitu kualitas udara di kota Bandung, dari parameter PM10, ISPU, suhu, dan kelembaban. Pemodelan LSTM dengan 4 *hidden layer*, penentuan jumlah *batch size* yaitu 32, penentuan *optimizer* adalah adam, *epoch* senilai 1000, dan penentuan fungsi *loss* menggunakan *mean squared error*. Hasil pemodelan LSTM menunjukkan bahwa jaringan memiliki kinerja yang cukup baik pada prediksi *training* dan *testing*. Pemodelan menghasilkan keakuratan prediksi yang cukup baik untuk 3 parameter (suhu, kelembaban, ISPU). Hal ini ditunjukkan dengan nilai RMSE prediksi yang lebih kecil dari nilai standar deviasi uji dataset. Namun, hasil prediksi yang dihasilkan dari keempat parameter pengujian berdasarkan urutan dari yang paling baik yaitu prediksi kelembaban, suhu, ISPU, dan PM10 dengan hasil prediksi yang kurang baik.

Kata Kunci— LSTM, prediksi, kualitas udara, PM10, ISPU

I. PENDAHULUAN

Salah satu masalah yang sering dihadapi di kota-kota besar yaitu polusi udara. Hal ini dipicu oleh banyaknya kendaraan transportasi, pengembangan infrastruktur, dan industri [1]. Sebagai salah satu kota besar, kota Bandung juga mengalami

hal yang sama. Berdasarkan data 2019 bahwa kota Bandung menjadi salah satu kota di Indonesia yang memiliki kualitas udara yang buruk. Hal ini dikarenakan konsentrasi partikel polutan pada kota tersebut sebesar 112,3 mikrogram per meter kubik telah lebih dari ambang batas yang ditetapkan oleh BMKG [2].

Beberapa penelitian sebelumnya menyatakan data kualitas udara adalah data runtun waktu atau *stochastic time series* sehingga proses peramalan dapat didasarkan pada data historis. Analisis *time series* adalah bagian dari prosedur statistik yang digunakan untuk peramalan struktur probabilitas situasi mendatang yang dapat dimanfaatkan dalam pengambilan keputusan [3]. Penelitian terkait prediksi *times series* untuk pengukuran kualitas udara telah banyak dilakukan, seperti prediksi tingkat polusi udara di kota Semarang menggunakan metode *general regression neural network* dengan hasil pemodelan menunjukkan kinerja yang baik dalam prediksi [4]. Prediksi PM10 di kota Pontianak dengan *neural network* menghasilkan prediksi cukup baik dengan koefisien korelasi 0,9673 [5]. Penelitian dengan mengembangkan model *neural network* yang tepat untuk memprediksi konsentrasi ozon dalam berbagai skala temporal sebagai fungsi dari variabel meteorologi dan parameter kualitas udara di kota Dilovasi, Turki yang merupakan kawasan industri dengan masalah polusi udara [6]. Penelitian untuk pemodelan pencemaran udara dengan kombinasi metode *neural network* dan *wavelet* pada data meteorologi dan polusi di kota Mataram, Nusa Tenggara Barat dengan hasil yang baik [7].

Algoritma *Long Short Term Memory* (LSTM) merupakan salah satu jenis arsitektur dari *Recurrent Neural Network* (RNN) yang biasa digunakan pada masalah-masalah yang berkaitan dengan *deep learning* [8]. Terdapat beberapa hasil penelitian yang menerapkan LSTM, di antaranya penelitian untuk prediksi nilai indikator pencemaran udara menggunakan Filter Kalman sebagai model penyesuaian yang dinamis [9]. Penelitian lainnya implementsai LSTM untuk prediksi lalu lintas [10]. Kedua penelitian tersebut menghasilkan akurasi prediksi yang cukup baik untuk data *time series* dengan

LSTM. Penelitian ini mengimplementasikan LSTM untuk prediksi suhu, PM10, kelembaban, dan ISPU.

II. METODOLOGI

Dalam penelitian ini tahapan yang dilakukan untuk membangun model prediksi suhu, PM10, kelembaban, dan ISPU, sebagai berikut:

1. Kajian pustaka terkait kualitas udara dan algoritma LSTM

1) ISPU

ISPU merupakan kondisi kualitas udara ambien pada suatu wilayah sebagai dasar dampak pada kesehatan mahluk hidup. Adapun parameter penentuan nilai ISPU seperti pada Tabel 1.

Kategorisasi kualitas udara didasarkan pada nilai ISPU sesuai dengan parameter pencemar utama. Adapun kategorisasi kualitas udara sesuai keputusan kepala Bapedal dapat dilihat pada Tabel II.

Particulate Matter (PM10) adalah partikel udara yang berukuran kecil, namun dampaknya dapat langsung dirasakan oleh mahluk hidup [12]. ISPU dengan rentang nilai 51-100 dapat mempengaruhi jarak pandang, rentang nilai 101-199 menyebabkan pengotoran debu, rentang nilai 200-299 akan sensitif pada penderita bronkhitis dan asma, dan nilai lebih dari 300 akan sangat berbahaya [13].

2) LSTM

LSTM merupakan varian dari unit *Recurrent Neural Network* (RNN). LSTM secara umum terdiri dari *cell*, *input gate*, *output gate*, dan *forget gate*. LSTM *neural network* sangat cocok untuk mengklasifikasi, memproses, dan membuat prediksi berdasarkan data *time series* karena mungkin ada kelangkaan durasi yang tidak diketahui di antara peristiwa penting dalam rangkaian waktu [14]. Arsitektur umum LSTM terdiri dari *memory cell*, *input gate*, *output gate*, dan *forget gate*. LSTM *cell* mengambil masukan dan menyimpannya untuk beberapa waktu. Secara intuitif, *input gate* mengontrol sejauh mana nilai baru akan berjalan ke dalam *cell*, *forget gate* mengontrol sejauh mana nilai tetap di

dalam *cell*, dan *output gate* mengontrol sejauh mana nilai dalam *cell* digunakan untuk menghitung aktivasi keluaran dari unit LSTM. Adapun arsitektur LSTM pada Gambar 1.

Data masuk pada *forget gates* akan diolah sesuai informasinya dan dipilih data yang akan disimpan pada *memory cell*. Fungsi aktivasinya menggunakan *sigmoid*. Persamaan (1) menggambarkan prinsip kerjanya, sedangkan *input gates* memiliki 2 *gate* yang menggunakan fungsi aktivasi *sigmoid* untuk memperbarui informasi dan menggunakan fungsi aktivasi *tanh* yang akan menyimpan nilai baru di *memory cell*. Hal ini dapat digambarkan pada persamaan (2) dan (3).

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2)$$

$$\hat{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (3)$$

Persamaan (4) adalah hasil gabungan nilai pada *input gate*. *Forget gate* akan menggantikan nilai *memory cell* oleh *cell gates*. Pada *output gates* juga terdapat 2 *gate* yaitu untuk memutuskan nilai yang akan dikeluarkan dengan fungsi aktivasi *sigmoid* dan menyimpan nilai dengan memakai fungsi aktivasi *tanh*. Hal ini dirumuskan pada persamaan (5) dan (6).


$$c_t = f_t * c_{t-1} + i_t * \hat{c}_t \quad (4)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (5)$$

$$h_t = o_t \tanh(c_t) \quad (6)$$

2. Pengumpulan Data

Data yang digunakan dalam penelitian ini memiliki format (Comma Separated Value), di mana nilai setiap parameter dipisahkan oleh titik koma. Data yang digunakan sebanyak 9.231 data dari hasil pencatatan mulai 19 Mei 2019 pukul 00:04:19 hingga 18 Agustus 2019 pukul 23:52:37. Data tersebut memiliki 21 parameter yaitu profil, tanggal, jam, O₃, CO, NO₂, SO₂, NO, CO₂, VOC, PM1, PM2.5, PM4, PM10, TSP, TEMP, HUM, WS, WD, ISPU dan status. Gambar 2 menunjukkan gambaran *dataset* yang dihasilkan.



Gambar 1 Arsitektur umum LSTM

TABEL I
PARAMETER DASAR UNTUK PENGUKURAN ISPU [11]

No	Parameter	Waktu Pengukuran
1	Partikulat (PM10)	24 jam
2	Sulfurdioksida (SO ₂)	24 jam
3	Karbonmonoksida (CO)	8 jam
4	Ozon (O ₃)	1 jam
5	Nitrogendioksida (NO ₂)	1 jam

TABEL II
KATEGORI KUALITAS UDARA BERDASARKAN NILAI ISPU [11]

No	Nilai ISPU	Kategori
1	0 – 50	Baik
2	51 – 100	Sedang
3	101 – 199	Tidak Sehat
4	200 – 299	Sangat Tidak Sehat
5	>300	Berbahaya

3. Pre-processing

Tahap normalisasi terhadap *dataset* dimulai dengan melakukan konversi tanggal dan jam ke dalam format *Datetime*. Dilanjutkan dengan menggabungkan tanggal dan jam sehingga diperoleh kolom *Datetime* sehingga ada perubahan *dataset* yang sebelumnya.

4. Data preparation untuk proses training dan proses testing

Pada tahap training, *dataset* akan dipisahkan menjadi 75% untuk *dataset training* dan 25% *dataset* untuk *testing*.

5. Proses Training

Sebelum memulai *training*, membuat pemodelan LSTM dengan 4 *hidden layer*, penentuan jumlah *batch size* yaitu 32, penentuan *optimizer* adalah *adam*, *epoch* senilai 1000, dan penentuan fungsi *loss* menggunakan *Mean Squared Error*. Proses *training* akan dilakukan, di mana model akan dilatih menggunakan *data training*. *Weight* dan *bias* akan terus diperbarui untuk mendapatkan model yang sesuai. Setelah sebuah iterasi proses *training*, maka dilakukan proses *validation*. *Validation* berguna untuk melihat seberapa baik model dari hasil *training*.

6. Proses Testing

Tahap ini akan membuat kembali model pembelajaran yang didapat dari proses *training* sebelumnya. Proses *testing* dilakukan untuk mengetahui efektivitas LSTM.

III. HASIL DAN PEMBAHASAN

Proses normalisasi *dataset* dimulai dengan melakukan konversi tanggal dan jam ke dalam format *Datetime*. Selanjutnya dilakukan kalkulasi *quantile* dari atribut untuk melihat *outlier*, kemudian dilanjutkan dengan pencarian dan interpolasi *outlier* sehingga diperoleh *dataset* pada Gambar 3.

1. Prediksi Suhu

Untuk memprediksi suhu digunakan parameter TEMP. Perbandingan hasil *plotting* terhadap *dataset* asli yang ditunjukkan pada Gambar 2 dan data yang sudah bertransformasi yang ditunjukkan pada Gambar 3 ditunjukkan pada Gambar 4.

Salah satu cara untuk mengimplementasikan tingkat akurasi hasil *testing* adalah melakukan evaluasi terhadap metode tersebut. Evaluasi ini akan menggunakan *Root Mean Squared Error* (RMSE). Untuk menghasilkan akurasi yang lebih baik, maka *epoch* diberi nilai 1000. Hasil perhitungan RMSE untuk *data training* dan *testing* adalah *train score* sebesar 2,37 RMSE dan *test score* sebesar 3,15 RMSE. Diperoleh performa yang cukup baik karena nilai RMSE prediksi lebih kecil dari nilai standar deviasi dari pengujian *dataset*, atau:

$$\text{RMSE of test prediction} < \text{Standard deviation of test dataset} \\ 3,15 < 4,40$$

No	Profile	Tanggal	Jam	O3	CO	NO2	SO2	NO	CO2	VOC	PM1	PM2.5	PM4	PM10	TSP	TEMP	HUM	WS	WD	ISPU	Status
1	BANDUNG	2019-05-19	00:04:19	21.35	0.78	6.77	14.06	26.168	409.86	251.202	0	0	0	2.77	0	21.4	100	0.6	5	9	BAIK
2	BANDUNG	2019-05-19	00:15:01	5.93	0.82	14.87	17.23	53.853	394.79	501.356	0	0	0	11.95	0	42.6	200	0	2	12	BAIK
3	BANDUNG	2019-05-19	00:30:06	6.62	0.63	22.24	2.31	38.304	390.66	753.291	0	0	0	12.71	0	63.6	299.2	0	2	13	BAIK
4	BANDUNG	2019-05-19	00:49:19	13.29	0.44	19	5.32	18.962	401.23	251.043	0	0	0	1.2	0	21.3	88.2	0.525	5	6	BAIK
5	BANDUNG	2019-05-19	01:04:19	2.44	0.47	26.74	13.61	35.27	381.67	250.471	0	0	0	3.52	0	21.3	97.4	0.975	5	9	BAIK
6	BANDUNG	2019-05-19	01:19:19	1.17	0.37	19.9	24.76	45.13	391.49	251.088	0	0	0	5.99	0	21.1	87.7	0.675	5	15	BAIK
7	BANDUNG	2019-05-19	01:49:19	7.84	0.28	21.16	21.9	39.063	392.45	249.623	0	0	0	0.37	0	20.5	100	0.375	4	14	BAIK
8	BANDUNG	2019-05-19	02:04:19	3.87	0.26	22.6	15.12	63.714	384.96	250.983	0	0	0	0.82	0	20.4	100	0.225	5	9	BAIK
9	BANDUNG	2019-05-19	02:15:44	4.66	0.37	24.4	36.82	41.338	402.94	251.399	0	0	0	11.39	0	19.9	100	0	1	23	BAIK
10	BANDUNG	2019-05-19	02:34:19	14.83	0.37	24.4	19.19	26.547	394.13	250.089	0	0	0	1.43	0	20.2	100	0.075	4	12	BAIK
11	BANDUNG	2019-05-19	02:49:19	2.44	0.33	25.12	34.11	73.574	402.94	251.712	0	0	0	12.31	0	20.1	90	0.075	5	21	BAIK
12	BANDUNG	2019-05-19	03:04:19	10.28	0.23	17.75	23.11	33.753	393.03	251.872	0	0	0	7.18	0	20.1	100	0.075	5	14	BAIK
13	BANDUNG	2019-05-19	03:19:19	3.6	0.29	27.1	38.33	40.959	407.26	252.28	0	0	0	1.06	0	20	100	0.225	5	24	BAIK
14	BANDUNG	2019-05-19	03:34:19	0.74	0.08	31.23	16.78	51.198	407.74	252.435	0	0	0	8.92	0	19.7	100	0	5	10	BAIK
15	BANDUNG	2019-05-19	03:49:19	4.34	0.12	27.82	19.34	48.164	397.39	252.408	0	0	0	1.64	0	19.6	100	0	5	12	BAIK
16	BANDUNG	2019-05-19	04:04:19	25	0.21	20.62	6.98	61.059	404.44	252.389	0	0	0	3.42	0	17.1	90	0	5	10	BAIK
17	BANDUNG	2019-05-19	04:19:18	9.59	0.28	19.54	23.26	45.889	404.57	252.622	0	0	0	8.22	0	19.3	100	0.15	5	15	BAIK
18	BANDUNG	2019-05-19	04:34:19	11.71	0.15	21.7	16.02	36.787	398.14	252.478	0	0	0	7.03	0	19.5	100	0.6	5	10	BAIK
19	BANDUNG	2019-05-19	04:45:35	32.47	0.17	19.72	28.23	69.782	390.19	2019.47	0	0	0	2.38	0	158	800	0	6	18	BAIK

Gambar 2 Bentuk *dataset* yang dihasilkan

	O3	CO	NO2	SO2	NO	CO2	VOC	PM1	PM2.5	PM4	PM10	TSP	TEMP	HUM	WS	WD	ISPU
Datetime																	
2019-05-19 01:00:00	3.816667	0.373333	22.600	20.090000	39.82100	388.536667	250.39400	0.0	0.0	0.0	3.293333	0.0	20.966667	95.033333	0.67500	4.666667	12.666667
2019-05-19 02:00:00	6.450000	0.332500	24.130	19.600833	51.29325	396.242500	251.04575	0.0	0.0	0.0	6.487500	0.0	20.150000	97.500000	0.09375	3.750000	13.833333
2019-05-19 03:00:00	4.740000	0.180000	25.975	19.111667	43.51850	401.355000	252.24875	0.0	0.0	0.0	4.700000	0.0	19.850000	100.000000	0.07500	5.000000	15.000000
2019-05-19 04:00:00	7.030833	0.202500	20.395	18.622500	53.37925	399.335000	252.22100	0.0	0.0	0.0	5.262500	0.0	18.950000	100.000000	0.18750	5.250000	13.250000
2019-05-19 05:00:00	9.321667	0.297500	27.545	18.227500	52.43100	393.270000	252.19325	0.0	0.0	0.0	6.510000	0.0	18.050000	100.000000	0.24375	5.000000	12.625000

Gambar 3 *Dataset* setelah normalisasi waktu

Gambar 5 adalah hasil prediksi suhu yang menghasilkan keakuratan prediksi yang cukup baik, di mana terlihat hasil prediksi pada grafik warna merah yang dibandingkan dengan data original yang berwarna biru.

2. Prediksi PM10


Untuk memprediksi PM10 digunakan parameter PM10. Perbandingan hasil *plotting* terhadap *dataset* asli (Gambar 2) dengan data yang sudah bertransformasi (Gambar 3) diperlihatkan pada Gambar 6.

Gambar 7 adalah hasil prediksi PM10 yang menghasilkan keakuratan prediksi yang kurang baik, di mana terlihat hasil


prediksi pada grafik warna merah yang dibandingkan dengan data original yang berwarna biru.

Hasil perhitungan RMSE untuk data *training* dan *testing* diperoleh adalah *train score* sebesar 1,92 RMSE dan *test score* sebesar 1,76 RMSE. Diperoleh performa yang kurang baik karena nilai RMSE prediksi lebih besar dari nilai standar deviasi dari pengujian *dataset*, atau:


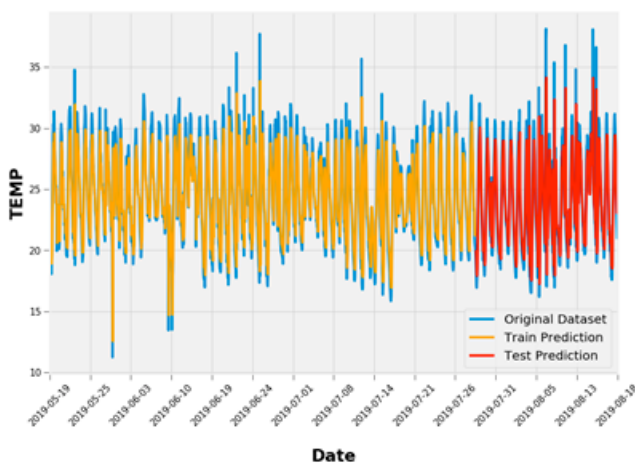
$$RMSE \text{ of test prediction} > \text{Standard deviation of test dataset} \\ 1,76 > 1,75$$





Gambar 4 Perbandingan data asli dan yang sudah ditransformasi dari TEMP



Gambar 6 Perbandingan data asli dan yang sudah ditransformasi dari PM10



Gambar 5 Hasil prediksi suhu



Gambar 7 Hasil prediksi PM10

3. Prediksi Kelembaban


Untuk memprediksi kelembaban digunakan parameter HUM. Perbandingan hasil *plotting* terhadap *dataset* asli (Gambar 2) dengan data yang sudah bertransformasi (Gambar 3) diperlihatkan pada Gambar 8.

Hasil perhitungan RMSE untuk data *training* dan *testing* adalah *train score* sebesar 7,56 RMSE dan *test score* sebesar 6,97 RMSE. Diperoleh performa yang cukup baik karena nilai RMSE prediksi lebih kecil dari nilai standar deviasi dari pengujian *dataset*, atau:

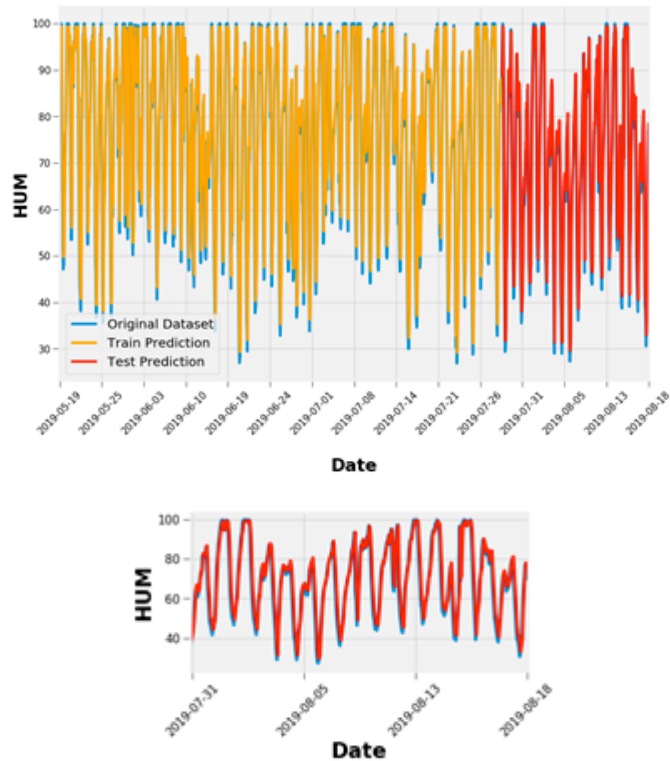
$$\text{RMSE of test prediction} < \text{Standard deviation of test dataset} \\ 6,97 < 19,32$$

Gambar 9 adalah hasil prediksi kelembaban yang menghasilkan keakuratan prediksi yang cukup baik, di mana terlihat hasil prediksi pada grafik warna merah yang dibandingkan dengan data asli yang berwarna biru.

4. Prediksi ISPU



Gambar 8 Perbandingan data asli dan yang sudah ditransformasi dari HUM



Gambar 9 Hasil prediksi kelembaban


Untuk memprediksi ISPU menggunakan parameter ISPU. Perbandingan hasil *plotting* terhadap *dataset* asli (Gambar 2) dengan data yang sudah bertransformasi (Gambar 3) diperlihatkan pada Gambar 10.

Hasil perhitungan RMSE untuk data *training* dan *testing* adalah *train score* sebesar 1,89 RMSE dan *test score* sebesar 1,85 RMSE. Diperoleh performa yang cukup baik karena nilai RMSE prediksi lebih kecil dari nilai standar deviasi dari pengujian *dataset*, atau:

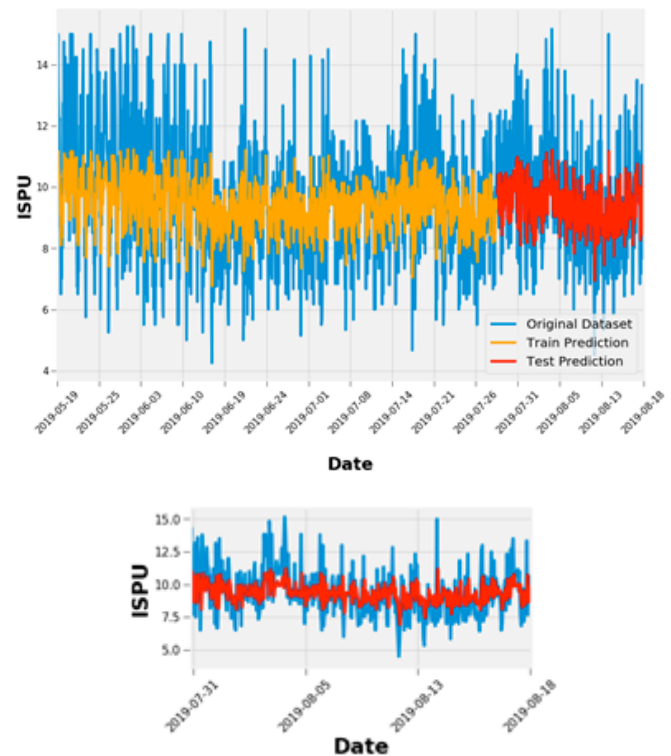
$$\text{RMSE of test prediction} < \text{Standard deviation of test dataset} \\ 1,85 < 1,90$$

Gambar 11 adalah hasil prediksi ISPU yang menghasilkan keakuratan prediksi yang agak membaik, di mana terlihat hasil prediksi pada grafik warna merah yang dibandingkan dengan data asli yang berwarna biru.

Tabel III merangkum perbandingan RMSE hasil prediksi dan standar deviasi hasil uji *dataset*.



Gambar 10 Perbandingan data asli dan yang sudah ditransformasi dari ISPU



Gambar 11 Hasil prediksi ISPU

TABEL III
PERBANDINGAN RMSE PREDIKSI DAN STANDAR DEVIASI UJI *DATASET*

Uji Prediksi	RMSE	
	Prediksi	Standar Deviasi
Suhu	3,15	4,40
PM10	1,76	1,75
Kelembaban	6,97	9,32
ISPU	1,85	1,90

IV. SIMPULAN

Pembentukan model LSTM dan penerapannya pada data *time series*, dengan 4 *hidden layer*, penentuan jumlah *batch size* yaitu 32, penentuan *optimizer* adalah *adam*, *epoch* senilai 1000 menghasilkan perhitungan terhadap data kualitas udara di kota Bandung untuk parameter PM10, ISPU, serta suhu dan kelembaban, menunjukkan bahwa model menghasilkan keakuratan prediksi yang cukup baik untuk 3 parameter (suhu, kelembaban, ISPU). Hal ini ditunjukkan dengan nilai RMSE prediksi yang lebih kecil dari nilai standar deviasi uji *dataset*. Namun, hasil prediksi yang dihasilkan dari keempat parameter pengujian yang paling baik adalah prediksi kelembaban diikuti oleh suhu, ISPU, dan PM10.

DAFTAR REFERENSI

- [1] A. Hermawan. "SPKU: Sistem Prediksi Kualitas Udara (Studi Kasus: Dki Jakarta)," Skripsi. University of Technology Yogyakarta, Indonesia, 2019.
- [2] Robotorial. (Agustus 2019). "Kualitas udara terbaik dan terburuk di Indonesia (Rabu, 21/08/2019)." [Daring]. Tersedia: <https://beritagar.id/artikel/berita/kualitas-udara-terbaik-dan-terburuk-di-indonesia-rabu-1082019> [21 Jun 2020]
- [3] M. Y. Fathoni, "Implementasi Metode *Fuzzy Time Series Cheng* untuk prediksi konsentrasi gas NO₂ di udara," *J. Sist. Inf. Bisnis*, vol. 7, no. 1, hlm. 17, Mei 2017.
- [4] B. Warsito, A. Rusgiyono, dan M. A. Amirillah., "Pemodelan *general regression neural network* untuk prediksi tingkat pencemaran udara kota Semarang," *Media Stat.*, vol. 1, no. 1, pp. 43–51, 2008.
- [5] Y. Aprianto, N. Nurhasanah, dan I. Sanubary, "Prediksi kadar *particulate matter* (PM10) untuk pemantauan kualitas udara menggunakan jaringan syaraf tiruan (studi kasus kota Pontianak)," *J. Positron*, vol. 8, no. 1, 2018.

- [6] B. Özbay, G. A. Keskin, Ş. Ç. Doğruparmak, dan S. Ayberk, "Predicting tropospheric ozone concentrations in different temporal scales by using multilayer perceptron models," *Ecol. Inform.*, vol. 6, no. 3–4, hlm. 242–247, Juli 2011.
- [7] S. Bahri, Syamsuddin, dan M. Hadijati, "Model *wavelet neural network* untuk pemodelan polusi udara di kota Mataram, Lombok, Nusa Tenggara Barat, Indonesia," dalam *Prosiding Seminar Nasional Matematika, Statistika, dan Aplikasinya*, 2019, hlm. 43–56.
- [8] X. Song, dkk., "Time-series well performance prediction based on Long Short-Term Memory (LSTM) neural network model," *J. Pet. Sci. Eng.*, vol. 186, hlm. 106682, Maet. 2020.
- [9] X. Song, J. Huang, dan D. Song, "Air quality prediction based on LSTM-Kalman model," dalam *2019 IEEE 8th Joint International Information Technology and Artificial Intelligence Conference (ITAIC)*, 2019, hlm. 695–699.
- [10] Z. Zhao, W. Chen, X. Wu, P. C. Y. Chen, dan J. Liu, "LSTM network: a deep learning approach for short-term traffic forecast," *IET Intell. Transp. Syst.*, vol. 11, no. 2, hlm. 68–75, Maret 2017.
- [11] "Keputusan Kepala Badan Pengendalian Dampak Lingkungan Nomor: Kep-107/Kabapedal/11/1997 tentang Pedoman Teknis Perhitungan Dan Pelaporan Serta Informasi Indeks Standar Pencemar Udara."
- [12] H.-L. Yu, Y.-C. Lin, dan Y.-M. Kuo, "A time series analysis of multiple ambient pollutants to investigate the underlying air pollution dynamics and interactions," *Chemosphere*, vol. 134, hlm. 571–580, Sept 2015.
- [13] A. Kurniawan, "Pengukuran parameter kualitas udara (CO, NO₂, SO₂, O₃ dan PM10) di Bukit Kototabang berbasis ISPU," *J. Teknosains*, vol. 7, no. 1, 2017.
- [14] A. Yadav, C. K. Jha, dan A. Sharan, "Optimizing LSTM for time series prediction in Indian stock market," *Procedia Comput. Sci.*, vol. 167, hlm. 2091–2100, 2020.

Ali Khumaidi, Dosen Teknik Informatika, Universitas Krisnadwipayana. Lahir di Pati dan menamatkan pendidikan tinggi dalam bidang Ilmu Komputer di Fakultas Ilmu Komputer, Universitas Indonesia dan Magister Ilmu Komputer STMIK Nusamandiri Jakarta. Memiliki keahlian dalam bidang *software engineering*, *data mining*, *machine learning*, dan *IoT*.

Ridwan Raafi'udin, kelahiran kota Cianjur. Lulus S1 Teknik Informatika Universitas Pembangunan Nasional Veteran Jakarta dan S2 Ilmu Komputer Universitas Budi Luhur. Status Dosen Tetap di UPN Veteran Jakarta. Peminatan di bidang *data science* dan *machine learning*.

Indra Permana Solihin, lahir di Jakarta pada 9 Agustus 1983. S1 Sistem Komputer Universitas Bina Nusantara. S2 Ilmu Komputer Universitas Budi Luhur. Dosen tetap di UPN Veteran Jakarta. Peminatan di *artificial intelligence*, *smart farming*, dan *IoT*.